



Российский государственный университет нефти и газа (НИУ) имени И.М. Губкина
ФАКУЛЬТЕТ КОМПЛЕКСНОЙ БЕЗОПАСНОСТИ ТЭК



ПРИКЛАДНАЯ СТАТИСТИКА

Королькова Наталия Андреевна,
Кандидат экономических наук



ЛЕКЦИЯ 5

Описательная статистика:
средние величины (структурные)
показатели вариации



Виды средних величин #напоминаю

степенные

по наличию признака – веса

простая средняя величина

взвешенная средняя величина

по форме расчета

средняя **арифметическая** величина

средняя **гармоническая** величина

средняя **геометрическая** величина

средняя **квадратическая** величина

и т.п.

структурные (описательные)

мода

медиана

квартили

децили

квинтили

перцентили

ЛЮБАЯ ИЗ
СРЕДНИХ
по форме расчета
может быть
ПРОСТОЙ
или
ВЗВЕШЕННОЙ



Медиана (Me) # повторение (вспоминаем!)

- ✓ значение, находящееся в середине вариационного ряда
- ✓ медиана делит ряд пополам, по обе стороны от нее будет одинаковое количество единиц совокупности
- ✓ ряд изначально (!) нужно упорядочить (ранжировать) по возрастанию

13 наблюдений

нечетное количество наблюдений

63	63	63	67	67	70	71	75	87	90	91	95	95
----	----	----	----	----	----	----	----	----	----	----	----	----

6 наблюдений «до»

6 наблюдений «после»

$$Me = V_7 = 71$$




Медиана (Me) # повторение (вспоминаем!)

- ✓ значение, находящееся в середине вариационного ряда
- ✓ медиана делит ряд пополам, по обе стороны от нее будет одинаковое количество единиц совокупности
- ✓ ряд изначально (!) нужно упорядочить (ранжировать) по возрастанию

14 наблюдений

четное количество наблюдений



7 наблюдений

7 наблюдений

$$Me = \frac{71 + 75}{2} = 73$$



Медиана (Me) # повторение (вспоминаем!)

для интервального вариационного ряда

Срок испытания, дни	Закрытые интервалы	Число скважин	Накопленная частота
до 5	0 – 5	30	30
5 – 10	5 – 10	50	80
10 – 15	10 – 15	54	134
15 – 20	15 – 20	60	194
20 – 25	20 – 25	30	224
25 – 30	25 – 30	16	240
свыше 30	30 – 35	10	250
Всего		250	

$$Me = x_0 + d \times \frac{\frac{\sum f}{2} - f_{Me-1}}{f_{Me}}$$

Me – медиана

x_0 – нижняя граница медианного интервала

d – величина медианного интервала

$\sum f$ – сумма частот ряда

f_{Me-1} – сумма накопленных частот в интервалах, предшествующих медианному

f_{Me} – частота медианного интервала

$$Me = 10 + 5 \times \frac{\frac{250}{2} - 80}{54} = 14,17$$



Квартили (Q)

- ✓ значение, делящее ранжированную совокупность на четыре равные части
- ✓ Q_1 – нижний квартиль – 1/4 часть совокупности с наименьшими значениями признака
- ✓ Q_2 – медиана – делит совокупность на две равные по количеству единиц части
- ✓ Q_3 – верхний квартиль – 1/4 часть совокупности с наибольшими значениями признака

13 наблюдений

нечетное количество наблюдений

63	63	63	67	67	70	71	75	87	90	91	95	95
----	----	----	----	----	----	----	----	----	----	----	----	----

6 наблюдений «до»

$$Q_1 = \frac{63 + 67}{2} = 65$$

$$Q_2 = Me = V_7 = 71$$

6 наблюдений «после»

$$Q_3 = \frac{90 + 91}{2} = 90,5$$



Квартили (Q)

- ✓ значение, делящее ранжированную совокупность на четыре равные части
- ✓ Q_1 – нижний квартиль – 1/4 часть совокупности с наименьшими значениями признака
- ✓ Q_2 – медиана – делит совокупность на две равные по количеству единиц части
- ✓ Q_3 – верхний квартиль – 1/4 часть совокупности с наибольшими значениями признака

14 наблюдений

четное количество наблюдений

63	63	63	67	67	70	71	75	87	90	91	95	95	96
----	----	----	----	----	----	----	----	----	----	----	----	----	----

7 наблюдений

$$Q_1 = V_4 = 67$$

$$Me = \frac{71 + 75}{2} = 73$$

7 наблюдений

$$Q_3 = V_{11} = 91$$



Квартили (Q)

для интервального вариационного ряда

Срок испытания, дни	Закрытые интервалы	Число скважин	Накопленная частота
до 5	0 – 5	30	30
5 – 10	5 – 10	50	80
10 – 15	10 – 15	54	134
15 – 20	15 – 20	60	194
20 – 25	20 – 25	30	224
25 – 30	25 – 30	16	240
свыше 30	30 – 35	10	250
Всего		250	

$$Q_1 = x_{Q_1} + d \times \frac{\frac{1}{4} \sum f - f_{Q_1-1}}{f_{Q_1}} \quad Q_3 = x_{Q_3} + d \times \frac{\frac{3}{4} \sum f - f_{Q_3-1}}{f_{Q_3}}$$

Q_1, Q_3 – нижняя граница интервала, содержащего нижний (верхний) квартиль

d – величина интервала

$\sum f$ – сумма частот ряда

f_{Q_1-1}, f_{Q_3-1} – сумма накопленных частот в интервале, предшествующему интервалу, содержащему нижний (верхний) квартиль

f_{Q_1}, f_{Q_3} – частота интервала, содержащего нижний (верхний) квартиль

$$Q_1 = 5 + 5 \times \frac{\frac{250}{4} - 30}{50} = 8,25 \quad Q_3 = 15 + 5 \times \frac{\frac{3 * 250}{4} - 134}{60} = 19,46$$



Децили (D)

- ✓ значение, делящее ранжированную совокупность на десять равных частей
- ✓ D_1 – первый дециль – 1/10 часть совокупности с наименьшими значениями признака
- ✓ D_2 – второй дециль – отделяет 2/10 частей совокупности от 8/10 частей и т.д.
- ✓ D_5 – медиана – делит совокупность на две равные по количеству единиц части

$$D_1 = x_{D_1} + d \times \frac{\frac{1}{10} \sum f - f_{D_1-1}}{f_{D_1}} \quad \dots \text{ и т.д.}$$

$$D_2 = x_{D_2} + d \times \frac{\frac{2}{10} \sum f - f_{D_2-1}}{f_{D_2}} \quad D_9 = x_{D_9} + d \times \frac{\frac{9}{10} \sum f - f_{D_9-1}}{f_{D_9}}$$



Квинтили (X)

- ✓ значение, делящее ранжированную совокупность на пять равных частей
- ✓ X_1 – первый квинтиль – 1/5 часть совокупности с наименьшими значениями признака
- ✓ X_2 – второй квинтиль – отделяет 2/5 частей совокупности от 3/5 частей и т.д.

$$X_1 = x_{X_1} + d \times \frac{\frac{1}{5} \sum f - f_{X_1-1}}{f_{X_1}}$$

$$X_3 = x_{X_3} + d \times \frac{\frac{3}{5} \sum f - f_{X_3-1}}{f_{X_3}}$$

$$X_2 = x_{X_2} + d \times \frac{\frac{2}{5} \sum f - f_{X_2-1}}{f_{X_2}}$$

$$X_4 = x_{X_4} + d \times \frac{\frac{4}{5} \sum f - f_{X_4-1}}{f_{X_4}}$$



Перцентили (P)

- ✓ значение, делящее ранжированную совокупность на сто равных частей
- ✓ P_1 – первый перцентиль – 1/100 часть совокупности с наименьшими значениями признака
- ✓ P_2 – второй перцентиль – отделяет 2/100 частей совокупности от 98/100 частей и т.д.
- ✓ P_{50} – медиана – делит совокупность на две равные по количеству единиц части

$$P_1 = x_{P_1} + d \times \frac{\frac{1}{100} \sum f - f_{P_1-1}}{f_{P_1}} \quad \dots \text{ и т.д.}$$



$$P_2 = x_{P_2} + d \times \frac{\frac{2}{100} \sum f - f_{P_2-1}}{f_{P_2}} \quad P_{99} = x_{P_{99}} + d \times \frac{\frac{99}{100} \sum f - f_{P_{99}-1}}{f_{P_{99}}}$$



- (!) средняя величина – недостаточная характеристика совокупности
- (!) показатели вариации служат **характеристикой типичности, надежности** самой средней
- (!) чем **меньше вариация**, тем более **показательна (типична) средняя** величина (рис. б)
- (!) чем **больше вариация** (индивидуальные значения сильно колеблются вокруг средней), тем **менее средняя типичная** для совокупности (рис. а)

○ – индивидуальные значения признака

Вариация – колеблемость, многообразие, изменчивость величины признака у отдельных единиц совокупности



Для того чтобы судить
об **однородности совокупности и типичности средней величины** изучаемого признака
необходимо вычислить **показатели вариации**



Показатели вариации

абсолютные показатели

размах вариации

межквартильный размах

среднее линейное отклонение

дисперсия

среднее квадратическое отклонение

- ✓ выражены в абсолютных величинах
- ✓ имеют ту же размерность, что и признак
- ✓ зависит от масштаба самих данных, что не позволяет сравнивать вариабельность в разных совокупностях

относительные показатели

коэффициент вариации

коэффициент осцилляции

линейный коэффициент вариации

- ✓ выражены в относительных величинах
- ✓ чаще всего выражаются в процентах
- ✓ для сравнения колеблемости различных признаков в одной и той же совокупности
- ✓ при сравнении колеблемости одного и того же признака в нескольких совокупностях




Размах вариации, амплитуда (R)

- ✓ разница между максимумом (max) и минимумом (min)

$$R = X_{max} - X_{min}$$

- ✓ зависит только от двух крайних значений признака, поэтому он **недостаточно отражает его колеблемость**
- ✓ является «**первым звоночком**» для проверки надежности средней как обобщающей типичной характеристики
- ✓ размах может быть очень широким и не иметь практического смысла при оценке
- ✓ **зависит от аномальных отклонений** [недостаток!]





Размах вариации, амплитуда (R)

✓ разница между максимумом (max) и минимумом (min)

Проектная команда	Табельный номер рабочего	Зарботная плата, рублей/месяц	Усредненная заработная плата по команде, рублей/месяц
1	1	12 000	15 175
	2	14 000	
	3	16 200	
	4	18 500	
2	5	9 600	15 175
	6	11 900	
	7	18 400	
	8	20 800	
Всего	8	121 400	15 175

$$R = X_{max} - X_{min}$$

1 проектная команда:

$$R_1 = 18\,500 - 12\,000 = 6\,500$$

2 проектная команда:

$$R_2 = 20\,800 - 9\,600 = 11\,200$$

(!) Средние одинаковые (!) $R_1 < R_2$ на 4 700 рублей




Межквартильный размах (range, IQR)

- ✓ реже называют интерквартильный размах/интервал (ИКР)
- ✓ разница между значениями третьего квартиля (Q_3) и первого квартиля (Q_1)

$$IQR = Q_3 - Q_1$$

- ✓ обычно представляются данные не о разности между квартилями, а указываются сами значения квартилей: Q_1 - Q_3
- ✓ не зависит от аномальных отклонений, то есть является робастным

$$Me = 55 (Q_1 - Q_3: 32 - 77)$$





Межквартильный размах (range, IQR)

для интервального вариационного ряда

Срок испытания, дни	Закрытые интервалы	Число скважин	Накопленная частота
до 5	0 – 5	30	30
5 – 10	5 – 10	50	80
10 – 15	10 – 15	54	134
15 – 20	15 – 20	60	194
20 – 25	20 – 25	30	224
25 – 30	25 – 30	16	240
свыше 30	30 – 35	10	250
Всего		250	

$$Me = 10 + 5 \times \frac{\frac{250}{2} - 80}{54} = 14,17$$

$$Q_1 = 5 + 5 \times \frac{\frac{250}{4} - 30}{50} = 8,25$$

$$Q_3 = 15 + 5 \times \frac{\frac{3 * 250}{4} - 134}{60} = 19,46$$

$$Me = 14,17 (Q_1 - Q_3: 8,25 - 19,46)$$




Среднее линейное (абсолютное) отклонение (L ; $\bar{d}$; СЛО)

- ✓ характеризует меру разброса индивидуальных значений вокруг их среднего значения
- ✓ дает лишь приближенную характеристику вариации
- ✓ формула расчета зависит от вида средней величины в основе (от типа данных)

Простое:
$$L = \frac{\sum |x - \bar{x}|}{n}$$

Взвешенное:
$$L = \frac{\sum |x - \bar{x}| * f}{\sum f}$$





Среднее линейное (абсолютное) отклонение (L ; $\bar{d}$; СЛО)

✓ характеризует меру разброса индивидуальных значений вокруг их среднего значения

Проектная команда	Табельный номер рабочего	Зарботная плата, рублей/месяц	Усредненная зарботная плата по команде, рублей/месяц
1	1	12 000	15 175
	2	14 000	
	3	16 200	
	4	18 500	
2	5	9 600	15 175
	6	11 900	
	7	18 400	
	8	20 800	
Всего	8	121 400	15 175

Простое: $L = \frac{\sum |x - \bar{x}|}{n}$

$$L_1 = \frac{|12\,000 - 15\,175| + |14\,000 - 15\,175| + |16\,200 - 15\,175| + |18\,500 - 15\,175|}{4} = 2\,175$$

$$L_2 = \frac{|9\,600 - 15\,175| + |11\,900 - 15\,175| + |18\,400 - 15\,175| + |20\,800 - 15\,175|}{4} = 4\,425$$



Среднее линейное (абсолютное) отклонение (L ; $\bar{d}$; СЛО)

✓ характеризует меру разброса индивидуальных значений вокруг их среднего значения

Разряд рабочего	Количество рабочих, человек <i>[вес; f]</i>	Зарботная плата по разряду, рублей/месяц <i>[признак; x]</i>	$x - \bar{x}$	$ x - \bar{x} * f$
1 разряд	367	30 500	-16 223	5 953 841
2 разряд	419	35 000	-11 723	4 911 937
3 разряд	628	37 000	-9 723	6 106 044
4 разряд	380	43 500	-3 223	1 224 740
5 разряд	231	53 000	6 277	1 449 987
6 разряд	82	57 000	10 277	842 714
Всего	2 107	—	—	20 489 263

$$\bar{x} = 46\,723$$

Взвешенное:

$$L = \frac{\sum |x - \bar{x}| * f}{\sum f}$$

$$L = \frac{20\,489\,263}{2\,107} = 9\,724$$



Дисперсия (σ^2 ; квадрат сигмы)

- ✓ **средний квадрат отклонений** индивидуальных значений от их средней величины
- ✓ дисперсия характеризует **разброс данных вокруг центра**
- ✓ **изначально рассчитывает на основе математического ожидания (!)**
- ✓ **НО:** не всегда можно вычислить матожидание, поэтому расчет выполняют на основе средней величины

Простое:
$$\sigma^2 = \frac{\sum (x - \bar{x})^2}{n}$$

Квадрат сигмы
сам по себе не имеет аналитической нагрузки

Промежуточный показатель

Взвешенное:
$$\sigma^2 = \frac{\sum (x - \bar{x})^2 * f}{\sum f}$$

Нужен для расчета самого точного
из абсолютных показателей вариации (СКО)



Среднеквадратическое (стандартное) отклонение (σ ; СКО)

- ✓ наиболее распространенный абсолютный показатель вариации
- ✓ квадратный корень из дисперсии

Простое:

$$\sigma = \sqrt{\frac{\sum (x - \bar{x})^2}{n}}$$

Взвешенное:

$$\sigma = \sqrt{\frac{\sum (x - \bar{x})^2 * f}{\sum f}}$$

На практике СКО может использоваться, прежде всего:

- ✓ в качестве меры изменчивости значений признаков
- ✓ в качестве степени отклонения желаемых показателей от наблюдаемых
- ✓ для обнаружения выбросов и аномальных значений в данных



Среднеквадратическое (стандартное) отклонение (σ ; СКО)

Проектная команда	Табельный номер рабочего	Зарботная плата, рублей/месяц	Усредненная зарботная плата по команде, рублей/месяц
1	1	12 000	15 175
	2	14 000	
	3	16 200	
	4	18 500	
2	5	9 600	15 175
	6	11 900	
	7	18 400	
	8	20 800	
Всего	8	121 400	15 175

Простое:

$$\sigma = \sqrt{\frac{\sum (x - \bar{x})^2}{n}}$$

$$\sigma_1 = \sqrt{\frac{(12000 - 15175)^2 + (14000 - 15175)^2 + (16200 - 15175)^2 + (18500 - 15175)^2}{4}} \\ = \sqrt{5\,891\,875} = 2\,427,32$$

$$\sigma_2 = \sqrt{\frac{(9600 - 15175)^2 + (11900 - 15175)^2 + (18400 - 15175)^2 + (20800 - 15175)^2}{4}} \\ = \sqrt{20\,961\,875} = 4\,578,41$$



Среднеквадратическое (стандартное) отклонение (σ ; СКО)

Разряд рабочего	Количество рабочих, человек <i>[вес; f]</i>	Зарботная плата по разряду, рублей/месяц <i>[признак; x]</i>	$x - \bar{x}$	$(x - \bar{x})^2 * f$
1 разряд	367	30 500	-16 223	96 589 162 543
2 разряд	419	35 000	-11 723	57 582 637 451
3 разряд	628	37 000	-9 723	59 369 065 812
4 разряд	380	43 500	-3 223	3 947 337 020
5 разряд	231	53 000	6 277	9 101 568 399
6 разряд	82	57 000	10 277	8 660 571 778
Всего	2 107	—	—	235 250 343 003

$$\bar{x} = 46\,723$$

Взвешенное:

$$\sigma = \sqrt{\frac{\sum (x - \bar{x})^2 * f}{\sum f}}$$

$$\sigma = \sqrt[2]{111\,651\,800} \\ = 10\,566,54$$



Коэффициент осциляции (V_R)

- ✓ мера оценки степени размаха вариации относительно средней величины

$$V_R = \frac{R}{\bar{x}} * 100$$

Коэффициент линейного отклонения (V_L)

- ✓ мера оценки степени СЛО относительно средней величины

$$V_L = \frac{L}{\bar{x}} * 100$$

Коэффициент вариации (V)

- ✓ мера оценки степени СКО относительно средней величины
- ✓ (!) наиболее часто употребляемый

$$V = \frac{\sigma}{\bar{x}} * 100$$



Коэффициент вариации (V)

- ✓ оценка **относительного разброса данных** в одной совокупности
 - ✓ оценка **однородности данных** в совокупности
 - ✓ **сравнение вариабельность в разных совокупностях**
- $$V = \frac{\sigma}{\bar{x}} * 100$$
-
- ✓ наиболее часто используется в области финансового и инвестиционного анализа:
 - определение **степени устойчивости прогнозных моделей** (в основном по инвестициям и портфельному инвестированию)
 - **осуществление XYZ-анализа**
 - **оценка «унифицированного риска» (unitized risk)**: расчет относительного разброса двух показателей по отношению к прогнозному значению



Коэффициент вариации (V)

✓ с позиции оценка **однородности данных** в совокупности

$$V = \frac{\sigma}{\bar{x}} * 100$$

Уровень коэффициента вариации	Содержательная характеристика
< 10%	Разброс признается незначительной; данные однородны
от 10% до 20%	Разброс значений считается на средне уровне
от 21% до 33%	Разброс признается значительным, но допустимым
> 33%	Данные неоднородны



Альтернативный признак

– признак, которым обладают одни единицы и не обладают другие единицы совокупности
[1 – есть признак; 0 – нет признака]

Среднее значение альтернативного признака

$$\bar{x} = \frac{1 * p + 0 * q}{p + q} = p$$

p – доля единиц, **обладающих признаком**, в численности всей совокупности

q – доля единиц, **не обладающих признаком**, в численности всей совокупности
($q = 1 - p$)

Дисперсия альтернативного признака

$$\begin{aligned}\sigma^2 &= \frac{(1 - p)^2 * p + (0 - p)^2 * q}{p + q} == q^2 * p + p^2 * q \\ &= p * q * (p + q) = \mathbf{p * q}\end{aligned}$$